

矩阵特征值的计算方式

幂法

设置方阵 A 的各特征值 λ 中仅有唯一的模长最大的值，且各特征矢 u_i 线性无关，即：

$$|\lambda_1| > |\lambda_2| \geq |\lambda_3| \geq \dots \geq |\lambda_n|$$

设 $x^{(0)}$ 是任意不为零的 n 维向量：

由迭代公式：

$$x^{(k+1)} = Ax^{(k)} \quad (4.1)$$

可以证明，在 k 足够大时，矩阵特征值 λ 是向量 $x^{(k+1)}$ 与向量 $x^{(k)}$ 的任意两个对应分量之商 $x_i^{(k+1)} / x_i^{(k)}$

证明：

由于 u_i 是 n 个 n 维向量且线性无关，故它是 $n \times 1$ 空间中的一组基底，故无论 $x^{(0)}$ 的取值，它总能被表示为 $x^{(0)} = \sum_{i=1}^n a_i u_i$ ，其中， a_i 不全为0。即 $x^{(0)}$ 是各个特征矢的线性组合。

则由迭代公式：

$$x^{(k+1)} = Ax^{(k)} = A^{k+1}x^{(0)} = \sum_{i=1}^n A^{k+1}a_i u_i = \sum_{i=1}^n \lambda_i^{k+1} a_i u_i$$

重写上述等式：

$$x^{(k+1)} = \lambda_1^{k+1} [a_1 u_1 + (\frac{\lambda_2}{\lambda_1})^{k+1} a_2 u_2 + (\frac{\lambda_3}{\lambda_1})^{k+1} a_3 u_3 + \dots + (\frac{\lambda_n}{\lambda_1})^{k+1} a_n u_n] \quad (4.2)$$

不妨假设 λ_1 是各个特征值中绝对值最大的一个，则在 k 充分大时，等式(4.2)可以截断为：

$$x^{(k+1)} \cong \lambda_1^{k+1} a_1 u_1 \quad (4.3)$$

此时， $x^{(k+1)}$ 可以看作是方阵 A 对应于特征值 λ_1 的一个特性矢。同时，在 k 充分大时，

$$x^{(k)} \cong \lambda_1^k a_1 u_1 \quad (4.4)$$

比较式子(4.3)和(4.4)，可以知道， $x^{(k+1)}$ 和 $x^{(k)}$ 线性相关，且线性系数之比为 λ_1

故，可以将 $x^{(k+1)}$ 和 $x^{(k)}$ 的任一对应分量 x_i 作比，有：

$$\lambda_1 = x^{(k+1)} / x^{(k)} \quad (4.5)$$



但是精妙的数学逻辑应用到计算机上就会变得粗糙，由于我们需要重复计算若干多次式(4.1)，向量 $x^{(k)}$ 中的分量可能出现溢出或舍入为0的情况. 故这时我们需要对每一次迭代出的向量 $x^{(k)}$ 进行归一化处理：

$$\begin{cases} y^{(k)} = \frac{x^{(k)}}{\|x^{(k)}\|_\infty} \\ x^{(k+1)} = Ay^{(k)} \end{cases}$$

由上述原理，在实际计算中，在式子(4.5)的分量选择过程中，我们应当选择绝对值最大的分量以消除舍入误差.

有效性讨论

- 1. 若不满足"仅有一个模取得最大值"的情况，由上述推导过程易知算法仍有效
- 2. 特殊地，若有 $\lambda_1 = -\lambda_2$ 时，迭代过程变为一摆动序列，则比较 k 足够大时的任意相邻三项即可得到求出 λ_1 和 u_1 与 u_2
- 3. 易知，算法的收敛速度取决于 $|\lambda_2|/|\lambda_1|$

迭代加速

原点移位法

设 λ_i 是 A 的特征值，则 $\lambda_i - \lambda_0$ 是 $A - \lambda_0 E$ 的特征值.

因此我们只需要找到合适的 λ_0 使得 $\forall i \in \mathbb{N}^*, |\lambda_1 - \lambda_0| > |\lambda_i - \lambda_0|$ 且 $\max \frac{|\lambda_i - \lambda_0|}{|\lambda_1 - \lambda_0|} < |\frac{\lambda_2}{\lambda_1}|$ ，我们就可以用矩阵 $A - \lambda_0 E$ 来代替矩阵 A ，从而获得更快的收敛过程.

但实践中我们不可能先验地知晓 A 的所有特征值，故此该方法在实际上难以精确地执行.

Aitken方法

我们称幂法中" k 足够大时， $x^{(k+1)}$ 和 $x^{(k)}$ 成比例"为一阶收敛. 若序列 a_k 一阶收敛至 a ，即：

$$\lim_{k \rightarrow \infty} \frac{a_{k+1} - a}{a_k - a} = c \neq 0$$

作近似：在 k 充分大时有：

$$\frac{a_{k+2} - a}{a_{k+1} - a} \approx \frac{a_{k+1} - a}{a_k - a}$$

解出 a 的表达式：

$$a' \approx a_k - \frac{(a_{k+1} - a_k)^2}{a_{k+2} - 2a_{k+1} + a_k}$$

每次进行幂法迭代之后，我们都依据上式计算一次 λ' ，若 λ' 与上一个 λ' 之间的误差满足条件，则输出结果.

函数插值法

已知平面上若干互不相同的点 $(x_0, y_0), (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$, 其关系属于某未知对应关系 $f(x)$, 如何构造一函数, 使得该函数可以穿过这些点并刻画 $f(x)$?

这种问题被称为插值问题, 上述的函数被称为插值函数.

Lagrange多项式法

Lagrange多项式法使用一个 n 次多项式来拟合上述的 $(n+1)$ 个点, 且可以得出唯一的结果.

证明:

对于点集 $\{(x_0, y_0), (x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$, 找到一 n 次多项式 $f(x) = a_0 + a_1x + a_2x^2 + \dots + a_nx^n$ 使得 $\forall x_i, f(x_i) = y_i$ 等价于方程组:

$$\begin{cases} f(x_0) = y_0 \\ f(x_1) = y_1 \\ \dots \\ f(x_n) = y_n \end{cases} \quad (4.6)$$

展开之, 可使其变为一个系数矩阵是范德蒙矩阵的关于多项式系数向量 A 的线性方程组, 且范德蒙矩阵在 x_i 互不相同时满秩.

多项式系数向量 A 存在且唯一.

■

我们对Lagrange多项式 (虽然还没有完全提出它的求解方式) 进行误差估计:

设置有若干节点 $(x_i, y_i), i \in [0, n]$ 是 $[a, b]$ 上的 $(n+1)$ 个互异节点, 若待拟合函数在 (a, b) 上 $(n+1)$ 阶可导, 即 $f(x) \in \mathbb{C}^{(n+1)}[a, b]$, 若我们用Lagrange多项式 $\phi(x)$ 拟合之, 则其插值余项 (截断误差) 可以表述为:

$$R_n(x) = f(x) - \phi(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x) \quad (4.7)$$

其中 $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i), \xi \in (a, b)$

直球使用微分中值定理即可**证明:**

由定义, $R(x) = f(x) - \phi(x)$, 再由Lagrange多项式的基本假设 (式4.6), 有 $\forall i, R(x_i) = 0$.

故可以等价地将 $R(x)$ 转写为 $R(x) = K(x)\omega_{n+1}(x)$, 其中 $\omega_{n+1}(x) = \prod_{i=0}^n (x - x_i)$, $K(x)$ 是某未知的多项式, 我们需要找到它:

使用惯用的套路构造辅助函数:

$$h(t) = R(t) - K(x)\omega_{n+1}(t)$$

观察到上述的函数有 $(n+2)$ 个零点： $x, x_0, x_1, x_2, \dots, x_n$ ，而我们事先约定这些零点都在 $f(x)$ 的解析域 (a, b) 上（否则Lagrange多项式将失去意义）

对自变量 t 反复应用罗尔中值定理 $(n+1)$ 次，则存在某一点 $\xi \in (a, b)$ ，使得：

$$h^{(n+1)}(\xi) = R^{n+1}(\xi) - K(x)(n+1)! = 0$$

故得到 $K(x) = \frac{R^{n+1}(\xi)}{(n+1)!}$ ， $\xi \in (a, b)$

而 $R(x) = f(x) - \phi(x)$ ， $\phi(x)$ 是一个 n 次多项式，在 $(n+1)$ 次求导后变为0，故

$$K(x) = \frac{f^{n+1}(\xi)}{(n+1)!}, \xi \in (a, b)$$

■

式4.7的意义在于，若记 $M = \max_{(a,b)} |f^{(n+1)}(x)|$ ，则Lagrange插值法的截断误差 $R(x) \leq \frac{M}{(n+1)!} \omega_{n+1}(x)$ ，这体现了对误差的一种控制。

Lagrange多项式的求解

最直观地，我们可以直接通过式(4.6)列方程组求解，但由于涉及到 n 次方运算，我们会得到一个范氏矩阵，而它往往是病态的，故考虑使用其它的方法求解。

事实上凡是要解方程求Lagrange多项式的，都会面临病态的问题，因此我们从方程形式上来考察它：

Lagrange多项式可以认为是一组线性无关的基 $1, x, x^2, x^3, \dots, x^n$ 线性组合而成的，因此我们可以构造另外一组与其同构的基来解决这一问题。我们构造这样的一组基底：

$$l_i(x), i \in [0, n], s.t : l_i(x) = \frac{\prod_{j=0, j \neq i}^n (x - x_j)}{\prod_{j=0, j \neq i}^n (x_i - x_j)}$$

这组基满足一个特殊的性质：对于点集中的若干离散 x ，当且仅当 $x = x_i$ 时 $l_i(x)$ 为1，否则为0，故我们可以构造插值函数如下：

$$f(x) = \sum_{i=0}^n y_i l_i(x) \tag{4.8}$$

容易得知上述的函数满足Lagrange插值的基本假设（式4.6）

但是基于4.8的Lagrange插值法具有一明显的弊端：即一旦点集发生改变，各个基均需要进行修改，故我们希望找到另外一组基，使得即使点集发生了增减，我们也只需简单地增加或删除一项即可：

Newton插值法

课本中对Newton插值的提法太过啰嗦，故给出一种额外的提法：

我们以一种逐步构建的方式来提出Newton插值.

1 最初, 我们的点集中只有 (x_0, y_0) , 因此我们给出插值式 $f_0(x) = y_0$ 来拟合之.

2 随后我们加入了点 (x_1, y_1) , 此时插值公式需要额外满足 $f(x_1) = y_1$, 根据Newton插值的思想, 我们通
过为 $f_0(x)$ 附加一项来达成此目的: (*s.t.*在数学符号中指"subject to", "使得")

$$f_1(x) = y_0 + R_1(x), \text{ s.t. } f_1(x_0) = y_0, f_1(x_1) = y_1$$

故 $R_1(x)$ 一定满足: $R_1(x_0) = 0, R_1(x_1) = y_1 - y_0$

故可以提出满足上述条件的 $R_1(x)$ 较为简单形式: $R_1(x) = b_1(x - x_0)$, 代入解出

$$b_1 = \frac{y_1 - y_0}{x_1 - x_0}$$

此时插值公式变为

$$f_1(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0}(x - x_0)$$

3 继续加入点 (x_2, y_2) , 此时插值公式需要额外满足 $f(x_2) = y_2$, 故仍使用上述的方式:

$$f_2(x) = y_0 + \frac{y_1 - y_0}{x_1 - x_0}(x - x_0) + R_2(x)$$

同理, 设置 $R_2(x) = b(x - x_0)(x - x_1)$, 解出

$$b_2 = \frac{\frac{y_2 - y_0}{x_2 - x_0} - \frac{y_1 - y_0}{x_1 - x_0}}{x_2 - x_1}$$

这个形式不够简洁, **经过简单的数学变换之后** (这种变换蕴藏着“均差(差商)的轮换对称性”, 后述), 可以
化为

$$b_2 = \frac{\frac{y_2 - y_1}{x_2 - x_1} - \frac{y_1 - y_0}{x_1 - x_0}}{x_2 - x_0}$$

我们发现它有着某种对称性: 我们定义 $f[a, b] = \frac{f(a) - f(b)}{a - b}$, 则 b_2 可以转写为:

$$b_2 = \frac{f[x_2, x_1] - f[x_1, x_0]}{x_2 - x_0}$$

这样的形式仍符合着某种更"高级"的对称性, 故我们将 b_2 记为 $f[x_0, x_1, x_2]$, 表示先求"较为低级的"两个
 $f[x_2, x_1]$ 和 $f[x_1, x_0]$, 再将其作差, 与外层的两个值之差 $x_2 - x_0$ 相除. 这样, 我们递归地提出了均差(差
商)的概念:

$$1. f[a, b] = \frac{f(a) - f(b)}{a - b}$$

$$2. f[a, a_1, \dots, b_1, b] = \frac{f[a, \dots, b_1] - f[a_1, \dots, b]}{a - b}, \text{ "..."} \text{ 可以为空且 } a_1, b_1 \text{ 可以相同 (即本式支持三个及以上项目)}$$

容易证明, 均差具有轮换对称性, 即只要参数的组合一致, 参数的排列与均差的值无关.

故Newton插值法可以直观地表述为：

$$f^*(x) = f(x_0) + (x - x_0)f[x_0, x_1] + (x - x_0)(x - x_1)f[x_0, x_1, x_2] + \dots$$

分析地描述为：

$$f^*(x) = \sum_{i=0}^n l_i(x) \quad (4.9-1)$$

$$l_i(x) = f[x_0 \text{ to } x_i] \prod_{j=0}^{i-1} (x - x_j) \quad (4.9-2)$$

请务必注意上述式子中连乘符号上的 $(i - 1)$ 。

Newton插值的截断误差

在非节点的任意点 $(x, f(x))$ 上，Newton插值的截断误差可以表述为：

$$R(x) = f^*(x) - f(x)$$

而 $f(x)$ 不可直接求知，因此采用一巧妙的解法：以点 $(x, f(x))$ 为第 $(n + 1)$ 个节点构造一新的Newton插值式 $f_{(n+1)}(x)$ ，而此式可以精确反映 $f(x)$ 的值。则易知其差值：

$$R(x) = f[x_0 \text{ to } x_n, x] \prod_{j=0}^n (x - x_j)$$

即为Newton插值的截断误差。而对于一个点系的插值式是唯一的，因此结合Lagrange插值法可以导出：

$$f[x_0 \text{ to } x_n, x] \omega_{n+1}(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$$

其中 ξ 在点集 (x_i, y_i) 连成的开区域内部，即

$$f[x_0 \text{ to } x_n, x] = \frac{f^{(n+1)}(\xi)}{(n+1)!}$$

等距均差和等距节点的Newton插值

如果上述过程中的节点都是等距的，即 $\forall i \in [0, n - 1], x_i - x_{i+1} \equiv h$ ，则均差可以改写为如下的形式(证明是简单的)：

$$f[x_a, x_{a+1}, \dots, x_{a+n}] = \frac{\Delta_{a+n,a}^n f}{n! h^n}$$

其中 $\Delta^n f$ 被称为 n 阶差分，根据差分与均差在内容上的一致性，我们可以递归地描述差分：

1. $\Delta_{a+1,a}^1 f = f(a+1) - f(a)$
2. $\Delta_{a+n,a}^n f = \Delta_{a+n-1,a}^{n-1} f - \Delta_{a+n,a+1}^{n-1} f$

至于所谓向前差分或向后差分，我们可以通过互换下角标顺序来描述(反正阶数又不会变)，又何必创造两个不同的符号呢？数学本来是简洁明快又可爱的，为什么要弄出这么多分裂的概念来让她变得啰嗦而丑陋呢？如是，我们即可重新以差分来改写节点等距情况下的Newton插值式：

$$f^*(x) = \sum_{i=0}^n l_i(x) \quad (4.10-1)$$

$$l_i(x) = \frac{\Delta_{i,0}^i f}{i!h^i} \prod_{j=0}^{i-1} (x - x_j) \quad (4.10-2)$$

直观地表述为

$$f^*(x) = f(x_0) + \frac{\Delta_{1,0}^1 f}{1!h^1} (x - x_0) + \frac{\Delta_{2,0}^2 f}{2!h^2} (x - x_0)(x - x_1) + \frac{\Delta_{3,0}^3 f}{3!h^3} (x - x_0)(x - x_1)(x - x_2) + \dots$$

而在某些情况下， x 会使用类似于等差数列的形式表示： $x = x_0 + ht$ ，这时我们可以使用 t 作自变量，将上述的式子再度改写：

$$f^*(x_0 + ht) = \sum_{i=0}^n l_i(t) \quad (4.11-1)$$

$$l_i(t) = \frac{\Delta_{i,0}^i f}{i!h^i} \prod_{j=0}^{i-1} (x_0 + th - (x_0 + jh)) = \Delta_{i,0}^i f \frac{\prod_{j=0}^{i-1} (t - j)}{i!} \quad (4.10-2)$$

直观地表述为

$$f^*(x_0 + ht) = f(x_0) + t\Delta_{1,0}^1 f + \frac{t(t-1)}{2!} \Delta_{2,0}^2 f + \frac{t(t-1)(t-2)}{3!} \Delta_{3,0}^3 f + \dots$$

这一式子被称为向前插值公式。代入求值时应注意自变量是 t ，若输入的是 x 则需相应的线性转化。

同理，若将 x 表示为 $x = x_n + ht$ ，也可以得出类似的结果：

$$f^*(x_n + ht) = \sum_{i=0}^n l_i(t) \quad (4.11-1)$$

$$l_i(t) = \frac{\Delta_{0,i}^i f}{i!h^i} \prod_{j=0}^{i-1} (x_0 + th - (x_0 + jh)) = \Delta_{0,i}^i f \frac{\prod_{j=0}^{i-1} (t - j)}{i!} \quad (4.10-2)$$

直观地表述为

$$f^*(x_0 + ht) = f(x_0) + t\Delta_{0,1}^1 f + \frac{t(t-1)}{2!} \Delta_{0,2}^2 f + \frac{t(t-1)(t-2)}{3!} \Delta_{0,3}^3 f + \dots$$

向前和向后插值都是基于式子(4.10)的，只不过对于 x 的等差数列表示不同。