

# 数值优化 (Numerical Optimization) 学习系列-二次规划 (Quadratic Programming)

下一步 于 2015-12-27 18:56:13 发布



数值优化 专栏收录该内容

94 订阅 17 篇文章

已订阅

## 概述

二次规划问题是目标函数是二次的，并且约束是线性的问题。在非线性约束最优化问题中非常重要，通常作为其他问题的子步骤存在。

1. 二次规划问题
2. 二次规划求解算法
3. 总结

## 二次规划问题

### 标准形式

二次规划问题的标识形式如下

$$\begin{aligned} \min q(x) &= \frac{1}{2}x^T Gx + x^T c \\ \text{s.t. } a_i^T x &= b_i, \quad i \in \mathcal{E} \\ a_i^T x &\geq b_i, \quad i \in \mathcal{I} \end{aligned}$$

如果矩阵G为半正定，则该问题为凸二次规划，否则为非凸二次规划。本节讨论重点凸二次规划问题。

## 二次规划求解算法

### 等式约束二次规划

在标准形式下，去掉不等式约束，可以得到等式约束二次规划问题的标准形式。

内容来源: [csdn.net](https://blog.csdn.net/fangqingan_java/article/details/49720497)

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/49720497](https://blog.csdn.net/fangqingan_java/article/details/49720497)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

$$\begin{aligned} \min q(x) &= \frac{1}{2}x^T Gx + x^T c \\ s. t. Ax &= b \end{aligned}$$

其中矩阵A一般为行满秩矩阵。

## KKT条件

根据KKT条件可以得到，最优解应该满足的一阶条件为

$$\begin{bmatrix} G & -A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x^* \\ \lambda^* \end{bmatrix} = \begin{bmatrix} -c \\ b \end{bmatrix}$$

当某搜索步骤x时，根据  $x^* = x + p$  代入上式公式，可以得到搜索步长。

$$\begin{bmatrix} G & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} -p \\ \lambda^* \end{bmatrix} = \begin{bmatrix} g \\ h \end{bmatrix}$$

其中  $h = Ax - b, g = c + Gx, p = x^* - x$ ，上面矩阵就是KKT矩阵。

1. 当是半正定时，KKT矩阵非奇异，等式约束最优化问题有唯一的解，其中Z是矩阵A的零空间，即AZ=0
2. 并且该解是全局最优解

## 求解算法

因此等式约束最优化问题转换为求解上述KKT矩阵对应的等式，常用的方法包括

1. 直接求解方程，高斯消元法等
2. Schur-Complement方法
3. 零空间方法

以上方法都是利用代数方法直接求解方程。对于问题规模比较大的问题可以采用迭代方法，例如CG或者Krylov方法，相对后者比较有效。

## 不等式约束问题

对于不等式约束问题，常见的思路包括有效集方法、内点法和梯度映射等方法。

## KKT条件

根据二次规划的标准形式可以得到，对应的拉格朗日方程为

内容来源：csdn.net

作者昵称：下一步

原文链接：https://blog.csdn.net/fangqingan\_java/article/details/49720497

作者主页：https://blog.csdn.net/fangqingan\_java

$$\mathcal{L}(x, \lambda) = \frac{1}{2}x^T Gx + x^T c - \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i (a_i^T x - b_i)$$

根据有效集的定义  $\mathcal{A}(x^*) = \{i \in \mathcal{E} \cup \mathcal{I} | a_i^T x^* = b_i\}$

KKT条件为

$$\begin{aligned} Gx^* + c - \sum_{i \in \mathcal{A}(\lambda_i^* a_i)} &= 0 \\ a_i^T x &= b_i, \quad i \in \mathcal{E} \\ a_i^T x &\geq b_i, \quad i \in \mathcal{I} \\ \lambda_i^* &\geq 0 \end{aligned}$$

满足上述KKT条件的解是全局最优解

## 有效集算法

该算法和线性规划的单纯形算法类似，每次固定一个工作集合，然后求解等式约束的QP问题。对于得到的解进行约束判断是否满足以及存在其他最优解，否则进行换入和换出操作。

1. 对于每次迭代过程，需要寻找一个最优搜索方向p，使得由于，因此问题转换为
2. 问题转换等式约束最优化问题，根据求解算法得到搜索方向
3. 由于不等式约束还要满足其他不等式，因此下一个搜索点，由于对于每个不等式都应该满足，当时肯定满足，否则
4. 综合所有的不等式约束，可以得到

$$\alpha_k = \min(1, \min_{a_i^T p_k \leq 0} (\frac{b_i - a_i^T x_k}{a_i^T p_k}))$$

5. 当某个  $\alpha_k < 1$  时，说明被第K个不等式阻塞，说明  $a_i^T p_k \leq 0$ ，此时可以将该不等式约束放入到工作集合中。
6. 当搜索方向p=0时，说明当前点为最优点，从而计算对应的拉格朗日因子，如果全部大于0，则满足所有的KKT条件，否则去掉该约束能够继续减小目标函数值。

综上该算法伪代码如下

内容来源: csdn.net

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/49720497](https://blog.csdn.net/fangqingan_java/article/details/49720497)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

**Algorithm 16.3** (Active-Set Method for Convex QP).

```

Compute a feasible starting point  $x_0$ ;
Set  $\mathcal{W}_0$  to be a subset of the active constraints at  $x_0$ ;
for  $k = 0, 1, 2, \dots$ 
    Solve (16.39) to find  $p_k$ ;
    if  $p_k = 0$ 
        Compute Lagrange multipliers  $\hat{\lambda}_i$  that satisfy (16.42),
            with  $\hat{\mathcal{W}} = \mathcal{W}_k$ ;
        if  $\hat{\lambda}_i \geq 0$  for all  $i \in \mathcal{W}_k \cap \mathcal{I}$ 
            stop with solution  $x^* = x_k$ ;
        else
             $j \leftarrow \arg \min_{j \in \mathcal{W}_k \cap \mathcal{I}} \hat{\lambda}_j$ ;
             $x_{k+1} \leftarrow x_k$ ;  $\mathcal{W}_{k+1} \leftarrow \mathcal{W}_k \setminus \{j\}$ ;
        else (*  $p_k \neq 0$  *)
            Compute  $\alpha_k$  from (16.41);
             $x_{k+1} \leftarrow x_k + \alpha_k p_k$ ;
            if there are blocking constraints
                Obtain  $\mathcal{W}_{k+1}$  by adding one of the blocking
                    constraints to  $\mathcal{W}_k$ ;
            else
                 $\mathcal{W}_{k+1} \leftarrow \mathcal{W}_k$ ;
    end (for)

```

实际考虑点

- 1.和单纯性算法类似，在算法开始，需要找到一个可行解，寻找方法类似，可以构造Phrasel或者Phrasell问题。
- 2.往工作集  $\mathcal{W}$  中添加不等式约束时，一般要求在  $\mathcal{W}$  中的约束线性独立。
- 3.当找到最优点时，但是不满足拉格朗日因子非负约束时，去掉约束时一般选择绝对值较大的。

## 内点法

类似于线性规划的内点法方法，计算问题的中心路径，直到趋近于最优解。

该内点法主要针对凸二次规划问题，形式如下

$$\begin{aligned} \min q(x) &= \frac{1}{2}x^T Gx + x^T c \\ \text{s. t. } Ax &\geq b \end{aligned}$$

KKT条件为

$$\begin{aligned} Gx - AT\lambda + c &= 0 \\ Ax - b &\geq 0 \\ (Ax - b)^T \lambda &= 0 \\ \lambda &\geq 0 \end{aligned}$$

内容来源: csdn.net

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/49720497](https://blog.csdn.net/fangqingan_java/article/details/49720497)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

添加松弛变量Y则有

$$\begin{aligned} \min q(x) &= \frac{1}{2}x^T Gx + x^T c \\ s. t. Ax &\geq b \end{aligned}$$

KKT条件为

$$\begin{aligned} Gx - AT\lambda + c &= 0 \\ Ax - y - b &= 0 \\ y^T \lambda &= 0 \\ (y, \lambda) &\geq 0 \end{aligned}$$

定义度量参数为  $\mu = \frac{y^T \lambda}{m}$ ，则问题转换为求解中心路径，

$$F(x, y, \lambda; \sigma\mu) = \begin{bmatrix} Gx - A^T \lambda + c \\ Ax - y - b \\ Y\Lambda e - \sigma\mu e \end{bmatrix} = 0$$

此时可以根据牛顿法进行求解得到步长，下下一个搜索点为  $(x, y, \lambda) + \alpha(\nabla x, \nabla y, \nabla \lambda)$

**在实际问题中会在此基础上改进，牛顿方程如何求解，参数λ如何选取**

## 梯度映射

梯度映射方法是对有效集算法的改进，不同于有效集算法，梯度映射方法每次都会选在多个参数变量加入到有效集中。但是该方法只限于求解如下问题

$$\begin{aligned} \min q(x) &= \frac{1}{2}x^T Gx + x^T c \\ s. t. l &\leq x \leq \mu \end{aligned}$$

对于G是否正定都能求解，思路如下

1. 在某步骤x，按照最速下降法求解下一个搜索点， $x_k + \alpha p$ ，由于约束限制，会被阻塞住，此时计算有效集。
2. 在上述有效集合的基础上，计算一个子问题，使得  $q(x^+) \leq q(x_k)$
3. 重复上述两个步骤。

## 总结

内容来源：csdn.net

作者昵称：下一步

原文链接：[https://blog.csdn.net/fangqingan\\_java/article/details/49720497](https://blog.csdn.net/fangqingan_java/article/details/49720497)

作者主页：[https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

本节简要介绍了如下内容

1. 二次规划问题的形式
2. 二次规划常用算法的求解思路。

详细算法的实现，可以参考各个数值工具。

内容来源: [csdn.net](https://blog.csdn.net/fangqingan_java/article/details/49720497)

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/49720497](https://blog.csdn.net/fangqingan_java/article/details/49720497)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)