

# 数值优化 (Numerical Optimization) 学习系列-信赖域方法

下一步 于 2015-12-27 18:45:43 发布



数值优化 专栏收录该内容

94 订阅 17 篇文章


已订阅

信赖域方法和线搜索类似都是迭代方法，与其不同的是，每次迭代时，在一个选定的**可信赖区域**内，选择当前迭代点的近似模型  $m_k$ ，然后计算最优步长；如果步长不合适，可以对区域进行缩放。该小结主要介绍：

1. 信赖域方法的基本形式
2. 求解信赖域的基础方法
3. 信赖域方法的收敛性和收敛速度
4. 信赖域方法的扩展

## 信赖域方法的基本形式

在信赖域方法中，可信赖的区域 (Region) 的选择很重要，一般都会根据上一步结果进行动态变化；如果上一步太大则缩小，否则进行扩大。



内容来源: csdn.net

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/46956643](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

在模型最优化问题中，选择TR方法比LS方法能够较快的收敛，例如在该例子中，在非凸函数F中，当前步骤TR方法要优于LS。

信赖域方法有几个参数需要选择：

1. 近似模型  $m_k$
2. 可信赖区域  $\Delta_k$
3. 求解参数  $p_k$

## 基本形式

在本节中模型选择为二次近似模型，采用函数二阶泰勒展开，即

$$f(x_k + p) = f_k + g_k^T p + \frac{1}{2} p^T \nabla^2 f_k p$$

一般情况下会用  $B_k$  去近似Hessian 矩阵<sup>Q</sup>，即

$$m_k = f_k + g_k^T p + \frac{1}{2} p^T B_k p$$

其中  $B_k$  为对称矩阵。

信赖域的基本形式为：

$$\min m_k(p) = f_k + g_k^T p + \frac{1}{2} p^T B_k p \quad \text{s.t. } \|p\| \leq \Delta_k$$

该问题为关于  $p$  的带约束的最优化问题，参数  $p$  被限制在一个球形区域内。如果  $B_k$  选择为Hessian，则为TR的牛顿方法。如果  $\|B_k^{-1} g_k\| \leq \Delta_k$  则  $p_k = -B_k^{-1} g_k$  为**完全步(Full Step)**，即球形约束没有作用。

## $\Delta_k$ 的选择

参数  $\Delta_k$  的选择一般会根据上一步的结果进行调整，定义

$$\rho_k = \frac{f_k - f(x_k + p_k)}{m_k(0) - m_k(p_k)}$$

其中分子表示函数实际减小的值；分母表示近似模型减少的值。分析  $\rho_k$ ：

1. 如果  $\rho_k$  小于0，一般情况下分母不可能小于0，因为目标函数求解的是最小值；此时说明分子小于0，即下一个目标点比上一步大，此时需要舍弃。
2. 如果  $\rho_k$  大于0并且接近1，说明模型和实际的预期比较相符合，此时可以考虑扩大  $\Delta_k$
3. 如果  $\rho_k$  大于0但是明显小于1，此时可以不用调整

内容来源：csdn.net

作者昵称：下一步

原文链接：https://blog.csdn.net/fangqingan\_java/article/details/46956643

作者主页：https://blog.csdn.net/fangqingan\_java

4. 如果 $\rho_k$ 大于0, 但是接近0, 说明模型变化范围比较大, 但是实际改变比较小, 此时应该收缩或者减少 $\Delta_k$

**Algorithm 4.1** (Trust Region).

Given  $\hat{\Delta} > 0$ ,  $\Delta_0 \in (0, \hat{\Delta})$ , and  $\eta \in [0, \frac{1}{4})$ :

**for**  $k = 0, 1, 2, \dots$

Obtain  $p_k$  by (approximately) solving (4.3);

Evaluate  $\rho_k$  from (4.4);

**if**  $\rho_k < \frac{1}{4}$

$$\Delta_{k+1} = \frac{1}{4} \Delta_k$$

**else**

**if**  $\rho_k > \frac{3}{4}$  and  $\|p_k\| = \Delta_k$

$$\Delta_{k+1} = \min(2\Delta_k, \hat{\Delta})$$

**else**

$$\Delta_{k+1} = \Delta_k;$$

**if**  $\rho_k > \eta$

$$x_{k+1} = x_k + p_k$$

**else**

$$x_{k+1} = x_k;$$

**end (for).**

具体算法如下:

## 子问题的最优解

为简化形式, 将信赖域问题的子问题表示为:

$$\min m(p) = f + g^T p + \frac{1}{2} p^T B p \quad \text{s.t. } \|p\| \leq \Delta$$

该问题为标准的带不等式约束的二次优化问题, 可以根据KKT条件 (后面会深入介绍) 得到该问题的最优解

### 定理

如果向量  $p^*$  为子问题的最优解, 当且仅当满足  $p^*$  为可行解, 并且存在标量  $\lambda$  满足

KaTeX parse error: No such environment: align at position 7: \begin{align} & (B + \lambda ...

其中条件 (b) 为补充条件, 即要么 $\lambda$ 为0要么 $\Delta = \|p^*\|$ 。

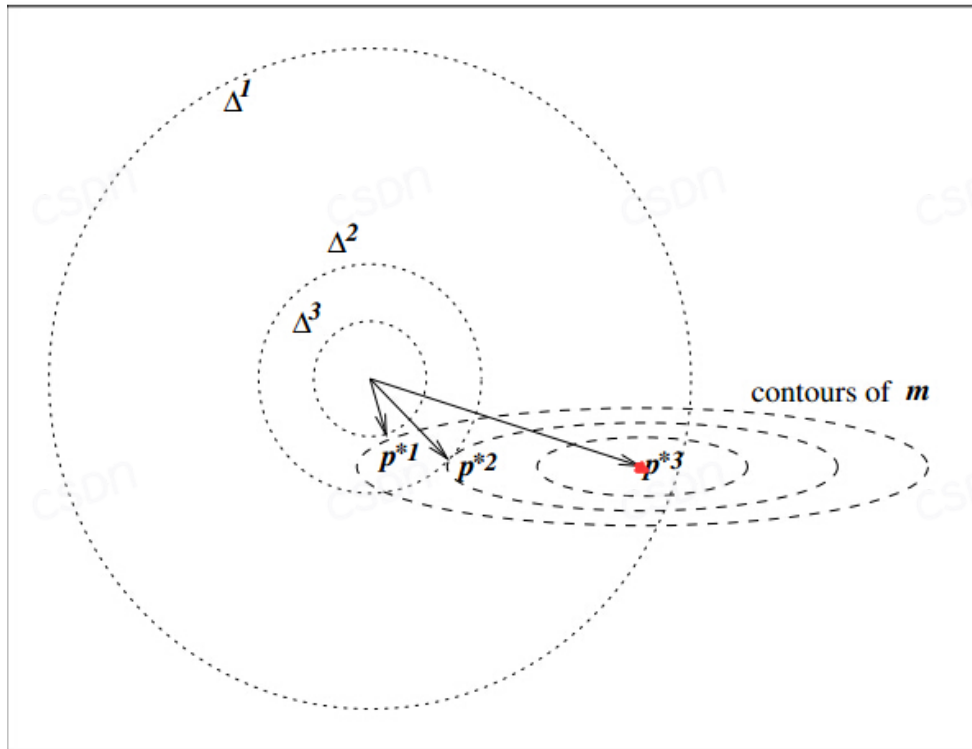
从下图中可以看出最优解和参数 $\lambda$ 的关系

内容来源: csdn.net

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/46956643](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)



当参数  $\Delta = \Delta^1$  时，最优解为  $p^3$  此时相当于没有约束，此时  $\lambda = 0$

当参数  $\Delta = \Delta^1$  或者  $\Delta^2$  时，最优解被球形约束限制，此时满足  $\Delta = \|p^*\|$ ，根据上面条件 (a) 有

$$\lambda p^* = -Bp^* - g$$

如果能够找到这样的  $p$  满足这些条件就能找到最优解。

## 基于柯西点 (Cauchy-Point) 的算法

在实际求解过程中不一定找到最优解，而是找到一个充分下降的点满足全局收敛即可。柯西点就是满足该条件的点 ( $p_k^c$ )

## 柯西点 (Caychy-Point) 算法

求解步骤如下

1. 计算原子问题的线性蜕化问题，寻找向量  $p_k^s$  满足

$$p_k^s = \arg \min f_k + g_k^T p \quad \text{s.t.} \quad \|p\| \leq \Delta_k$$

内容来源: csdn.net

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/46956643](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

2. 寻找标量 $\tau_k > 0$ 满足  $\min m_k(\tau p_k^s)$  同时满足信赖域的约束，即

$$\tau_k = \arg \min m_k(\tau p_k^s) \quad \text{s.t.} \quad \|\tau p_k^s\| \leq \Delta_k$$

$$3. p_k^c = \tau_k p_k^s$$

分别解释如下：

1. 计算 $p_k^s$  从上述步骤1中可以看出求解步骤1有必使解， $p_k^s = -\frac{\Delta_k}{\|g_k\|}g_k$ 。两种思路，一是退化后的函数为线性函数，而且是递减的，只要取下界即可。二是利用KKT条件也可以推出。
2. 将求解得到的 $p_k^s$ 代入子问题可以得到，

$$\begin{aligned} \min m(p) &= f + g^T p + \frac{1}{2} p^T B p \quad \text{s.t.} \quad \|p\| \leq \Delta \\ \min m(\tau p_k^s) &= f - g^T \tau \frac{\Delta_k}{\|g_k\|} g_k + \frac{1}{2} \tau^2 \frac{\Delta_k}{\|g_k\|} g_k^T B_k \frac{\Delta_k}{\|g_k\|} g_k \\ &\quad \text{s.t.} \quad \|\tau p_k^s\| \leq \Delta_k \end{aligned}$$

是一个关于 $\tau$  的二次函数，如果

1)  $g_k^T B_k g_k \leq 0$ ，是一个关于 $\tau$ 的递减函数，直接得到 $\tau = 1$

2)如果 $g_k^T B_k g_k > 0$  求导可以得到KaTeX parse error: Undefined control sequence: \e at position 68: ...时\tau需要满足 \tau \underline{e}\_1

柯西点很容易计算，但是如果只利用柯西点，相当于只利用了梯度方向，相当于线搜索的扩展而已，即**收敛速度为线性收敛**。

## Dogleg算法

该方法适用于当 $B_k$ 正定时，寻找半径 $\Delta$ 和最优解 $p^*(\Delta)$ 之间的关系。

在之前定义了完全步(Full Step)，即 $\|B_k^{-1}g_k\| \leq \Delta_k$ 则  $p_k^B = -B_k^{-1}g_k$

该算法的思路为， $p^*(\Delta)$ 表示不同 $\Delta$ 条件下的最优解，

1)  $p^*(\Delta) = p^B \quad \|p^B\| \leq \Delta$ ，否则

2)

$$p(\tau) = \begin{cases} \tau p^u, & 0 < \tau < 1 \\ p^u + (\tau - 1)(p^B - p^u), & 1 < \tau < 2 \end{cases}$$

内容来源：csdn.net

作者昵称：下一步

原文链接：https://blog.csdn.net/fangqingan\_java/article/details/46956643

作者主页：https://blog.csdn.net/fangqingan\_java


其中 $p^u$ 定义为

$$p^u = -\frac{g^T g}{g^T B g} g$$

，沿着梯度方向的最优解。

此为Dogleg方法，即寻找一个折线即两个线段的交点，即一条线段是沿着负梯度方向的最优值；二是沿着 $p^u$ 到 $p^B$ 方向。在此折线上寻找最优解。

由定理可以证明 $\|p(\tau)\|$ 是一个关于 $\tau$ 的递增函数，而 $m(p(\tau))$ 是一个关于 $\tau$ 的递减函数，又是一个线性函数，因此只要计算 $p(\tau)$ 和 $\|p\| = \Delta$ 的交点



即可。从下图可以清晰看到

## 二维子空间最优优化

在DogLeg算法中，可以理解为最优解 $p^*$ 可以表示为 $p^u$ 和 $p^B$ 的扩展子空间，即 $p^* = \lambda_1 g + \lambda_2 B^{-1}g$ ，则原子问题可以表示为：

$$\begin{aligned} \min m(p) &= f + g^T p + \frac{1}{2} p^T B p \\ \text{s.t } \|p\| &\leq \Delta \\ p &\in \text{span}[g, -B^{-1}g] \end{aligned}$$

## 迭代算法

根据子问题的最优解形式可以得到

1) 当 $\lambda = 0$ 时需要满足

$$B p^* = -g$$

内容来源: [csdn.net](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/46956643](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

$$\begin{aligned} & \mathbf{B} \text{ 正定} \\ & \|\mathbf{p}^*\| \neq \Delta \end{aligned}$$

2) 当 $\lambda \neq 0$ 时需要满足

$$\begin{aligned} (\mathbf{B} + \lambda \mathbf{I})\mathbf{p}^* &= -\mathbf{g} \\ \mathbf{B} + \lambda \mathbf{I} &\text{正定} \\ \|\mathbf{p}^*\| &= \Delta \end{aligned}$$

即

$$\|\mathbf{p}^*\| = \|-(\mathbf{B} + \lambda \mathbf{I})^{-1}\mathbf{g}\| = \Delta$$

通过定义 $\mathbf{p}(\lambda) = -(\mathbf{B} + \lambda \mathbf{I})^{-1}\mathbf{g}$ , 寻找特定的 $\lambda$ 使得 $\|\mathbf{p}(\lambda)\| = \Delta$

### 相关定义

由于 $\mathbf{B}$ 正定因此可以进行正交分解, $\mathbf{B} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^T$ ;  $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ 并且 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$

$$\begin{aligned} \mathbf{B} + \lambda \mathbf{I} &= \mathbf{Q}(\mathbf{\Lambda} + \lambda \mathbf{I})\mathbf{Q}^T \\ \mathbf{p}(\lambda) &= \mathbf{Q}(\mathbf{\Lambda} + \lambda \mathbf{I})^{-1}\mathbf{Q}^T\mathbf{g} \\ p(\lambda)^2 &= -\sum_1^n \frac{(\mathbf{q}_j^T \mathbf{g})^2}{(\lambda_j + \lambda)^2} \end{aligned}$$

由于是正交分解因此 $\mathbf{q}_i \mathbf{q}_j = 1$

### 迭代算法

1) 由上述定义

$$p(\lambda)^2 = -\sum_1^n \frac{(\mathbf{q}_j^T \mathbf{g})^2}{(\lambda_j + \lambda)^2}$$

可以看出

2) 当 $\lambda > -\lambda_1$ 时函数值是一个单调递减函数, 特别当 $\lim_{\lambda \rightarrow \infty} (p(\lambda)^2) \rightarrow 0$


内容来源: [csdn.net](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/46956643](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)

3)因此我们需要寻找 $\lambda \in (-\infty, \lambda_1)$ 使得 $\|p\| = \Delta$



### $\lambda$ 求解

在 $q_i^T g \neq 0$

1) 通过牛顿迭代法求解

$$\phi(\lambda) = \|p(\lambda)\| - \Delta = 0$$

2) 近似算法求解

$$\begin{aligned} \phi_1(\lambda) &= \frac{C1}{\lambda + \lambda_1} + C2 \\ \phi_{11}(\lambda) &= \frac{1}{\Delta} - \frac{\lambda + \lambda_3}{C3} \end{aligned}$$

当 $q_i^T g = 0$ 是一个Hard Case, 此时可以添加一个误差因子进行近似

内容来源: [csdn.net](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/46956643](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)



$$\mathbf{p}(\lambda) = \mathbf{Q}(\mathbf{\Lambda} + \lambda \mathbf{I})^{-1} \mathbf{Q}^T \mathbf{g} + \tau \mathbf{E}$$

## 信赖域的其他扩展

1. poor scaling问题，可以扩展为球形或者椭圆形
2. 可以构造Scaled的算法

$$\min \mathbf{m}(\mathbf{p}) = \mathbf{f} + \mathbf{g}^T \mathbf{p} + \frac{1}{2} \mathbf{p}^T \mathbf{B} \mathbf{p} \quad \text{s.t. } \|\mathbf{D} \mathbf{p}\| \leq \Delta$$

3. 矩阵D的构造和 $\partial^2 f / \partial \mathbf{x}_i$ 相关
4. 可以构造通用的柯西点法
5. 其他Norm方法，例如

$$\begin{aligned} \|\mathbf{p}\|_1 &\leq \Delta \\ \|\mathbf{p}\|_\infty &\leq \Delta \end{aligned}$$

## 总结

通过该节需要了解

1. 信赖域方法和线搜索方法的不同
2. 信赖域方法的基本形式
3. 信赖域方法的柯西点算法、DogLeg算法和最优解迭代算法
4. 信赖域方法收敛

内容来源: csdn.net

作者昵称: 下一步

原文链接: [https://blog.csdn.net/fangqingan\\_java/article/details/46956643](https://blog.csdn.net/fangqingan_java/article/details/46956643)

作者主页: [https://blog.csdn.net/fangqingan\\_java](https://blog.csdn.net/fangqingan_java)