

数值优化 (Numerical Optimization) 学习系列-概述

下一步 于 2015-12-27 18:43:01 发布



数值优化 专栏收录该内容

94 订阅 17 篇文章

已订阅

开篇

1. 数值优化通过迭代的方式解决优化问题，是数学建模中关键的一环。
2. Modeling过程，需要确定优化目标、目标所依赖的变量以及变量之间的约束关系，最后通过优化算法解决问题。

基础

1. 对于一个优化问题，通常有一个优化目标函数 $f(x)$ x 为参数变量， $c(x)$ 为约束。
2. 最优化问题的标注形式为

$$\begin{aligned} \min f(x) \quad & x \in \mathbb{R}^n \\ \text{s.t. } C_i(x) = 0 \quad & i \in \mathcal{E} \\ C_i(x) \geq 0 \quad & i \in \mathcal{I} \end{aligned}$$

3. 其中 \mathcal{E} 表示等式集合， \mathcal{I} 表示不等式集合
4. 其中满足约束的解称之为 **可行解**

问题分类

根据目标函数或者约束函数的不同，对于最优化问题可以分为：

- 连续/离散优化问题
- 约束/非约束优化问题
- 线性/非线性优化问题
- 全局/局部优化问题
- 随机/确定性优化问题

内容来源：csdn.net

作者昵称：下一步

原文链接：https://blog.csdn.net/fangqingan_java/article/details/46289691

作者主页：https://blog.csdn.net/fangqingan_java

凸优化

对于凸优化需要了解几个概念，详细可以参考Stephen Boyd的《凸优化》，里面对凸优化问题进行了详细的介绍。

1. 凸集：如果集合S为凸集，当且仅当 $x \in S, y \in S$ 并且 $\alpha(x) + (1 - \alpha)(y) \in S; \alpha \in [0, 1]$
2. 凸函数：如果函数f(x)为凸函数，当且仅当S为凸集， $x \in S, y \in S; \alpha f(x) + (1 - \alpha)f(y) \geq f(\alpha x + (1 - \alpha)y); \alpha \in [0, 1]$
3. 严格凸函数，凸函数能够取到非等号，即 $\alpha \in (0, 1)$
4. 凸优化问题：对于标准形式目标函数为凸函数，等式约束为线性约束；不等式约束为凹函数。

无约束最优化问题

在 **机器学习** 中，有大量的问题可以归约为无约束最优化问题，例如线性回归、LR等。因此对于无约束问题的研究也很深入从简单的GD、SGD、TR到CG、Newton、(L-)BFGS等

1. 无约束最优化问题可以表示为 $\min f(x); x \in \mathbb{R}^n$
2. 全局最优解 VS 局部最优解
 - * 全局最优简单理解为在整个定义域内解最小
 - * 局部最优：在某个邻域内解最小
3. 对于凸优化问题，任何局部最优解都是全局最优解。

局部最优解几个定理

1. 泰勒展开公式，根据泰勒公式对于函数f(x)可以近似为一阶展开近似： $f(x) \approx f(x_0) + \nabla f(x_0)^T(x - x_0)$
二阶展开近似： $f(x) \approx f(x_0) + \nabla f(x_0)^T(x - x_0) + \frac{1}{2}(x - x_0)^T \nabla^2 f(x_0)(x - x_0)$
2. 局部最小值的一阶必要条件，如果 x^* 为局部最优解并且函数f一阶可导，则在 x^* 的邻域内 $\nabla f(x^*) = 0$
3. 局部最优解的二阶必要条件，如果 x^* 为局部最优解并且一阶和二阶可导，则 $\nabla f(x^*) = 0$ 并且 $\nabla^2 f(x)$ 正定
证明：对于定理2，3的证明采用反证法。例如对于定理2. 假设 $\nabla f(x^*) \neq 0$ ，则根据泰勒一阶展开则可以找到 $\nabla f(x^*)^T(x - x^*) \leq 0$
4. 局部最优的二阶充分条件：如果函数f在 x^* 处满足 $\nabla f(x^*) = 0$ 并且 $\nabla^2 f(x)$ 正定，则 x^* 为局部最优解
5. 如果函数f为凸函数，则f的任何局部最优解都为全局最优解。

优化算法概述

在后面会介绍一系列解决该问题的算法，先介绍几个简单的概念。

1. 通过数值优化算法求解，一般会给定初始点 x_0 ，找到一系列点 $x_1, x_2, x_3 \dots x_n \rightarrow x^*$

内容来源：csdn.net

作者昵称：下一步

原文链接：https://blog.csdn.net/fangqingan_java/article/details/46289691

作者主页：https://blog.csdn.net/fangqingan_java

2. 通常有两大类比较重要的策略 线搜索 (Line Search) 和信赖域 (Trust Region)

3. Line Search策略：假设在某点 x_k ，寻找方向 p_k 和步长 α 使得 $\min f(x_k + \alpha p_k)$ 最小，如果 p_k 确定则只需要解决一维最优化问题就可以找到下一个搜索点，如何确定 p_k 后面介绍几类策略，最简单的策略就是当前点的梯度。
4. Trust Region策略：在某点 x_k 解决优化问题 $\min m_k(x_k + p_k)$ ，其中 m_k 为函数 f 在 x_k 点的近似，同时为保证 m_k 为一个较好的近似，即当 p_k 远离 x_k 时偏离太大，则需要保证 $x_k + p_k$ 在一个可信赖的区域内；
5. 通常情况下信赖域选择为椭圆、球或者盒状区域，即一个凸集容易找到最优解。
6. 模型 m_k 一般可以选择为函数的泰勒二阶近似，即

$$m(x_k + p) \approx f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T \nabla^2 f(x_k) p$$

其中 B_k 为Hessian矩阵或者其近似

7. 以上两类策略的相同点是在某点 x_k 通过解决一个优化问题找到下一个搜索点。LS首先选择方向 p_k 通过解决一维最优化问题找到步长 α ；TR首先对步长进行约束，通过解决简单的优化问题寻找搜索方向。

线搜索中搜索方向选择

1. 最速下降方向，即搜索方向选择为负梯度方向： $p_k = -\nabla f_k$ 。由泰勒展开公式 $f(x_k + \alpha p_k) \approx f(x_k) + \alpha \nabla f(x_k)^T p_k + \frac{1}{2} \alpha^2 \nabla^2 f(x_k) p_k^T p_k$ ，由于 $\nabla^2 f_k$ 满足正定，因此只需要 $\nabla f(x_k)^T p_k$ 最小。即 $\min f(x_k + \alpha p_k) s.t. ||p_k|| = 1$ ；可以推出 $p_k = -\nabla f_k / ||\nabla f_k||$ 。主要问题对于复杂问题效率较慢
2. 通用搜索方向：从泰勒展开公式上可以看到，只要满足 $\nabla f_k^T p_k \leq 0$ 都可以选择为搜索方向，问题是相比最速下降效率可能会较低。
3. 牛顿方向(Newton direction, p_k^N)， $p_k^N = -(\nabla^2 f_k)^{-1} \nabla f_k$ ，解释如下

$$\text{泰勒公式: } m_k(p) = f(x_k + p) \approx f(x_k) + \nabla f(x_k)^T p + \frac{1}{2} p^T \nabla^2 f(x_k) p$$

$$\begin{aligned} \min m_k(p) \\ \Rightarrow \nabla m_k(p) &= 0 \\ \Rightarrow \nabla f_k + \nabla^2 f_k p &= 0 \\ \Rightarrow p_k^N &= -(\nabla^2 f_k)^{-1} \nabla f_k \end{aligned}$$

关于 p_k^N 1) 当 $\nabla^2 f_k$ 正定时满足 $p_k^T \nabla f_k = -p_k^T \nabla^2 f_k p_k \leq 0$ 满足函数值下降，为有效搜索方向。2) 当 $\nabla^2 f_k$ 非正定时， $-(\nabla^2 f_k)^{-1}$ 不一定存在，即使存在也不一定满足下降条件。

4. 伪牛顿方向(Quasi-Newton 方向)， $p_k = -B_k^{-1} \nabla f_k$ ，由于Hessian矩阵计算复杂度较高而且不一定能够满足正定，可进行近似。

$$\text{泰勒公式: } \nabla f(x_k + p) \approx \nabla f(x_k) + \nabla^2 f(x_k) p$$

由于 $x_{k+1} = x_k + p$ ，令

$$s_k = x_{k+1} - x_k$$

$$y_k = \nabla f_{k+1} - \nabla f_k$$

$$\Rightarrow y_k = B_{k+1} s_k (\text{伪牛顿条件})$$

内容来源: csdn.net

作者昵称: 下一步

原文链接: https://blog.csdn.net/fangqingan_java/article/details/46289691

作者主页: https://blog.csdn.net/fangqingan_java

将 $f(x)$ 在点 x_{k+1} 处进行泰勒展开

$$f(x) \approx f(x_{k+1}) + \nabla f(x_{k+1})^T (x - x_{k+1}) + \frac{1}{2} (x - x_{k+1})^T \nabla^2 f_{k+1} (x - x_{k+1})$$

在 $x = x_k$ 的梯度为

$$\nabla f_k \approx \nabla f_{k+1} + \nabla^2 f_{k+1} (x_k - x_{k+1})$$

$$y_k = B_{k+1} s_k$$

在实际使用中一般还对 B_{k+1} 添加一些附加条件，例如对称、正定以及低秩等，两个比较常用的近似算法为SR1和BFGS

5. 非线性共轭梯度方向： $p_k = -\nabla f_k + \beta_k p_{k-1}$ ，后面会详细介绍该算法。

信赖域模型

1. 对于LS中的共轭方向外，其他方向的模型均可以引入到TR中
2. 例如，牛顿方向 $m_k(x_k + p)$ 中将 $B_k = 0$ 对应于TR模型中

$$\min f_k + \nabla_k^T p \quad s.t. \|p\|_2 \leq \Delta_k$$

$$\Rightarrow p_k = -\frac{\Delta_k \nabla f_k}{\|\nabla f_k\|}$$

SCALING 问题

1. 一个poor scaled 问题是指函数 $f(x)$ 在某个方向上的变化比其他方向的变化，带来更大的函数值改动。即某个方向的微小改动带来巨大函数响应，例如 $f(x) = 10^9 x_1^2 + x_2^2$ 对 x_1 方向的变化比较敏感。
2. 可以通过变量重定义的方式解决问题。
3. 线搜索问题中的最速下降法是poor scaled算法，Newton算法也会受到影响。最速下降法对于条件数比较大的问题会带来之字迭代，收敛速度大幅下降

总结

几个重要的知识点

1. 优化问题的标准形式（后续的学习中以此为准）
2. 凸优化问题：凸集、凸函数
3. 全局最优解 VS 局部最优解
4. 局部最优解的一阶、二阶必要条件，可证明

内容来源：csdn.net

作者昵称：下一步

原文链接：https://blog.csdn.net/fangqingan_java/article/details/46289691

作者主页：https://blog.csdn.net/fangqingan_java

5. 线搜索常用搜索方向；信赖域常用模型

6. poor scaled问题

内容来源: [csdn.net](https://blog.csdn.net/fangqingan_java/article/details/46289691)

作者昵称: 下一步

原文链接: https://blog.csdn.net/fangqingan_java/article/details/46289691

作者主页: https://blog.csdn.net/fangqingan_java